

第四章 — Solana ↔ Ethereum 跨链套利的端到端实证

匿名

1 SOLANA ↔ ETHEREUM 跨链桥概览

当前在 Solana 与 Ethereum 生态之间持续运行、且支持通用资产转移的主流跨链桥共有五条：Wormhole Portal、LayerZero V2、Mayan Finance、Relay 与 Chainlink CCIP。它们在信任模型、费用结构与验证机制上分别采用不同路线，由此在延迟、费率与单笔上限上呈现显著差异。表 1 汇总其主要参数与我们可以采集到的跨链事件量级。

Table 1: Solana ↔ Ethereum 跨链桥对比

协议	信任/验证	费用模式	记录数
Wormhole Portal	Guardian 多签签发 VAA	按 gas 计	42,181
LayerZero V2	DVN 验证	DVN 费	271,813
Mayan Finance	Dutch auction	约 3 bps	10,653,600
Relay	Intent-based fill	可变 bps	107,220
Chainlink CCIP	DON + risk manager	LINK 费	2,115

五条桥中，Wormhole 与 CCIP 采用基于多方证明人的“消息层 + 代币包装”模型；LayerZero 由 DVN 网络与上层 Oracle/Relayer 分层验证；Mayan 与 Relay 则将跨链结算建模为“订单/拍卖”模式，由 solver 竞价填单。架构差异直接决定了：(i) 跨链事件是否在链上有可核验的 1:1 指纹；(ii) 一次跨链转移能否被单一公开字段精确配对为 (src, dst) 二元组；(iii) 是否存在由中间人定价的“延迟-费用”异质性。这三点恰好是我们后续能否重建每一次跨链套利 PnL 的关键前提。

2 为何选 WORMHOLE：数据与套利候选构造

2.1 为何以 Wormhole Portal 为研究对象

在前述五条桥中，我们选择 Wormhole Portal 作为唯一的长期样本来源。原因可归纳为四点：(i) 链上可核验。Portal 的每条消息由 Guardian 集群以密码学签名背书，并以 VAA (Verifiable Action Approval) 形式上链，使我们无需依赖任何链下台账即可将 Solana 签名与 Ethereum 交易哈希 1:1 配对；(ii) 标准化配对。两链上的 Token Bridge 合约采用固定的 emitter/recipient 字段结构，使 (arb_{sol}, arb_{eth}) 这一“行为者”主键可以直接从链上解码；(iii) 传输与执行解耦。Portal 只完成代币的包装/释放，其后在目标链上的 DEX 执行是独立的链上事件，使得入场 swap、桥腿、出场 swap 可以分别归因；(iv) 代币覆盖最广。对跨链套利最活跃的长尾 memecoin，Wormhole 通过 WTT 与 NTT 标准所支持的代币集合是其余四条桥

的真超集，因此“仅采 Wormhole”不会对套利现象引入显著的样本选择偏差。

2.2 数据采集流水线

图 1 展示 5 阶段的采集与匹配流水线。Wormhole 官方的 /operations API 按 VAA 索引，但仅保留约 7 天的历史——不足以支持一年期分析。我们因此从两条链的 Portal 智能合约反向出发：(1) 分别在 Ethereum 与 Solana 上扫描 Portal Token Bridge 合约的完整日志/指令，解析出每笔 bridge 事件的 src_chain_id 与 dst_chain_id；(2) 以每笔事件的 Solana 签名或 Ethereum 交易哈希作为查询键，通过 wormholescan 的按签名/哈希搜索接口回溯对应的 VAA（此路径不受 7 天窗口限制）；(3) 以 VAA (emitterChain + sequence) 为外键，将两链端的签名/哈希合并为统一的跨链记录；(4) 通过 Birdeye 的 1 秒级价格接口查询入场/出场时刻的代币-USD 汇率；(5) 以贪心配对算法把 bridge 事件前后的同 wallet swap 归因到本次跨链，形成 (direction, sol_sig, eth_hash, entry_swaps, exit_swaps, C_{exec}ⁱⁿ, Π_{net}) 的候选样本。

符号约定。· 全章使用如下符号：C_{exec}ⁱⁿ 表示入场 swap 的 USD 等值本金（execution capital, 即 entry notional）；f_{total} 为两链上 gas 与桥接费合计的总手续费；gross 为入场-出场两次 swap 合并计算的毛利润（未扣手续费）；Π_{net} = gross - f_{total} 为扣除手续费后的净 PnL；资本回报率定义为

$$ROI = \Pi_{net} / C_{exec}^{in}, \quad (1)$$

文中一律以百分数呈现。




Figure 1: 数据采集与套利候选构造流水线。

3 跨链利润的决定因子：描述性证据

本节回答研究问题：在描述性层面，净 PnL Π_{net} 与哪些可观测量相关、与哪些无关。图 3 汇总了经济学层面的六个子结果。

Figure 2 — Timing of Wormhole Portal Arbitrage




Figure 2: Wormhole Portal 套利的的时间结构: (a) 按方向的桥接延迟 CDF; (b) 入/出场 swap 与桥接事件的时间差; (c) 按桥接延迟档位分层的 ROI 分布。

Figure 3 — Economics of Wormhole Portal Arbitrage (ROI, Size, Fees, PnL)




Figure 3: 跨链套利经济学: (a) ROI 直方图 + 内嵌 CDF; (b) 按方向分 ROI CDF; (c) 入场本金的对数分布与资本分层; (d) 手续费 / |gross PnL| 比值分布; (e) Gross vs. Net PnL 散点 (颜色编码本金); (f) 净 PnL 对 $\log_{10}(C_{\text{exec}}^{\text{in}})$ 的 OLS 回归。

分布形态 (面板 a/b)。ROI 重尾且偏左, 中位 +1.39%、78.0% 样本为正; SOL→ETH 方向的 CDF 左尾略

薄, ETH→SOL 略厚, 但两方向中位 ROI 差 <1 百分点, 方向本身的解释力有限。表 2 给出可靠候选的 ROI 完整

分位数结构；重尾特征十分明显：p1 仅 -49% 而 p99 高达 +152%，std/median 超过 48 倍，均值 +7.83% 被少数极端正样本显著上拉，偏离中位数 +1.39% 达 5.6 倍。

Table 2: 可靠候选的 ROI 分位数 ($n = 29,340$, 单位%)

统计量	值	分位	值	分位	值
count	29,340	p1	-49.65	p75	+3.77
mean	+7.83	p5	-4.15	p90	+10.66
std	67.07	p10	-1.51	p95	+27.79
min	-125.28	p25	+0.20	p99	+152.40
max	+5,204.09	p50	+1.39	—	—

ROI 最小值 -125.28% (亏损超过 100%) 并非计算错误：依式 (1)，当 $f_{\text{total}} > C_{\text{exec}}^{\text{in}}$ 时分子 Π_{net} 的负值量级可超过分母 $C_{\text{exec}}^{\text{in}}$ ，使 ROI 在数学上穿过 -100%；最极端的 LOVE 样本入场本金 \$1.00、总手续费 \$1.13，实属真实的经济亏损而非测量误差。

资本与 PnL 几近无关 (面板 c/f)。在对数横轴上，入场本金跨越七个数量级。对 $n = 29,128$ 的可靠候选以

$$\Pi_{\text{net}} = \alpha + \beta \cdot \log_{10}(C_{\text{exec}}^{\text{in}}) + \varepsilon \quad (2)$$

拟合 OLS (α 为截距、 β 为斜率、 ε 为残差)，得到 $\hat{\beta} = -1,085 \text{ \$/decade}$ (即本金每增加一个 10 倍量级， Π_{net} 的期望下降约 \$1,085)、 $R^2 = 0.0027$ 。也就是说，本金仅解释净 PnL 方差的 0.27%。面板 (f) 的 binned median 曲线在 10^2 - 10^4 USD 区间近似平坦并略微大于零，两端显著下沉，呈倒 U 形。这一反直觉结果否定了“跨链套利是资本可线性放大之生意”这一朴素假设。

费用是一阶约束 (面板 d/e)。费率 $\text{fee}/|\text{gross}|$ (以 $\text{fee} = f_{\text{total}}$ 为总手续费、 gross 为两次 swap 的毛利) 的分布范围极宽，中位 0.053，但有 2.8% 的候选出现 $\text{fee} > |\text{gross}|$ 的严重侵蚀。面板 (e) 所有点都在 $y = x$ 的下方，纵向位移直接可视化了费用开销；左下角的密集簇是“毛利不足以覆盖 gas”的大量小额亏损。

时间结构 (图 2)。图 2 从三个角度刻画跨链候选的时间属性：(a) 按方向的桥接延迟 CDF——SOL→ETH (蓝) 中位数 ~34 秒，ETH→SOL (红) 中位数 ~1,011 秒 (~17 分钟)，两者差约 30 倍，恰好对应 Solana 亚秒级的 slot finality 与 Ethereum 两个 epoch finality 之间的差距；两条 CDF 仅在远右尾趋近 (均有 $p_{99} > 4,000$ 秒)；(b) swap-bridge 时序——入场 swap 与桥接调用的时间差中位数 ~12 秒，出场端更长 (~24 秒)，右尾拖至小时级，说明少量候选在桥后持仓等待出场，这也为把桥事件前后同钱包的 swap 归并到同一跨链候选的贪心配对提供了经验支持；(c) 按桥接延迟档位分箱的 ROI 箱线图——<60 秒档 ($n = 14,599$ ，中位 +1.39%) 与 60-300 秒档 ($n = 2,639$ ，中位 +1.04%) 均优于 1-24h 档 (中位 +0.13%)，>24h 档更跌至 -1.35%；300 秒-1h 档样本量最大 ($n = 14,449$ ，中位 +1.50%) 反映了主流 ETH→SOL 路

径的中位延迟区间。面板 (c) 直接支撑了表 3 中“桥接延迟负向显著”的断言。

本节总结的“相关/无关”清单。表 3 汇总上述描述性证据。这些断言均为单变量结论；其中一些变量在第 4 节的多变量模型中会被重新评估。

Table 3: 描述性层面 Π_{net} 与各变量的关系

变量	关系	证据
入场价差	正向显著	前人工作 + 分层
桥接延迟	负向显著	图 2(c)+ 模型
流动性深度	非线性	liquidity tier 分层
手续费	负向 (恒等式)	图 3(d/e)
入场本金	$R^2 = 0.003$ ，几无解释力	图 3(f)
方向	差异 < 1pp	图 3(b)
日内小时	近似均匀	(略)
Swap 拆分数	无显著效应	图 2(b)

4 整合建模与实验

§3 的结论全部是单变量的。若特征之间存在交互，单变量关系会失效。本节用一个多变量非线性模型从两个并列的角度复核：回归——预测 Π_{net} 的美元金额；分类——预测 $\mathbf{1}\{\Pi_{\text{net}} > 0\}$ 的盈亏方向 ($\mathbf{1}\{\cdot\}$ 为指示函数，条件为真取 1、为假取 0)。

4.1 特征集合

我们以 17 个特征覆盖六类假设驱动，均在候选级别可观测：方向/时间 (dir_sol_to_eth, hour_utc)、规模/延迟 (log_size, log_latency)、原子性 (atomic_entry_same_block, atomic_exit_same_block)、swap-bridge 时序 (entry_delta_bridge_sec, exit_delta_bridge_sec, n_entry_swaps, n_exit_swaps)、测量完整性 (entry_coverage, exit_coverage)、流动性分层与市场 (liq_dead, liq_thin, liq_healthy, entry_gap_pct, actor_trade_count)。

4.2 模型规格

两个模型共享相同的加性树集成结构：

$$F_M(x) = \sum_{m=1}^M \eta \cdot h_m(x), \quad (3)$$

其中 h_m 为深度 3 的回归树， $M = 200$ ，学习率 $\eta = 0.05$ 。每棵树拟合在前一步残差上的负梯度方向：

$$h_m = \arg \min_h \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + h(x_i)), \quad (4)$$

拟合前按 subsample = 0.8 做无放回行采样以降低方差。

回归目标（“赚多少美元”）。目标为按美元 winsorize 后的 Π_{net} ：

$$y_i^{\text{reg}} = \text{clip}(\Pi_{\text{net},i}, -\$100, +\$500), \quad (5)$$

其中 $\text{clip}(z, a, b) = \max(a, \min(b, z))$ 为区间截断；损失为半平方误差 $L_{\text{reg}}(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2$ 。裁剪区间 $[-\$100, +\$500]$ 的设计理由有四：(i) 原始 Π_{net} 分布极端长尾（ $\min \approx -\$2.07\text{M}$, $\max \approx +\$428\text{K}$ ），不做裁剪时单个 outlier 在 MSE 下的梯度达 $O(10^{12})$ ，会主导整棵树的分裂方向；(ii) $[-\$100, +\$500]$ 覆盖 95.8% 的候选样本（仅 2.5% 下截、1.7% 上截），绝大多数样本保留原始值，仅尾部被 winsorize；(iii) 上下限有意不对称： Π_{net} 的中位数 $+\$3.14$ 、 $p_{75} \approx +\$10$ ，整体右偏；亏损端集中在单笔手续费量级（ $\$20-50$ ），所以 $-\$100$ 已对应“显著糟糕”， $+\$500$ 则保留了赢家前 ~3% 的异质性；(iv) 裁剪仅作用于回归头；分类头 y^{cls} 仍看原始正负号，“是否盈利”的信息在系统层面没有丢失。

分类目标（“赚不赚”）。目标为盈利指示：

$$y_i^{\text{cls}} = \mathbf{1}\{\Pi_{\text{net},i} > 0\}, \quad (6)$$

损失为二元交叉熵 $L_{\text{cls}}(y, \hat{p}) = -y \log \hat{p} - (1-y) \log(1-\hat{p})$ ，模型输出概率 $\hat{p}_i = \sigma(F_M(x_i))$ ，其中 $\sigma(z) = 1/(1+e^{-z})$ 为 logistic sigmoid。下单决策由阈值 $\tau \in (0, 1)$ 得出： $\hat{y}_i^{\text{cls}} = \mathbf{1}\{\hat{p}_i > \tau\}$ 。

4.3 评估协议

训练集限定为 `pnl_complete` 且 17 特征无缺失的 $n = 15,497$ 条。采用 $K = 5$ 折随机 KFold (`random_state=42`)：每折在 4/5 数据上训练、1/5 上测试，汇报 K 折均值 $\pm$ 标准差：

$$R_{\text{CV}}^2 = \frac{1}{K} \sum_{k=1}^K R_k^2, \quad \text{AUC}_{\text{CV}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}_k. \quad (7)$$

回归报告 R^2 、MAE、Median AE；分类报告 AUC、Log-Loss，并在两个工作阈值 $\tau \in \{0.5, 0.8\}$ 下报告

$$\text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}, \quad (8)$$

其中 TP, FP, FN 分别为给定阈值 τ 下的真阳、假阳、假阴样本数（真阳 = 模型判盈且实际盈利；假阳 = 模型判盈但实际亏损；假阴 = 模型判亏但实际盈利）。分类的朴素基线为“全部判为盈利”，准确率即数据正例率 $\bar{y}^{\text{cls}} = \frac{1}{n} \sum_{i=1}^n y_i^{\text{cls}} = 73.85\%$ 。

4.4 交叉验证结果

表 4 汇总 5 折 CV 表现。回归 $R_{\text{CV}}^2 = 0.799 \pm 0.027$ ——相比式 (2) 的单变量 $R^2 = 0.003$ 提升逾两个数量级，证明 Π_{net} 在本章 17 特征下是可预测的，但要求多变量非线性模型。Median AE = $\$5.13$ 意味着至少一半样本被预测到 $\pm \$5$ 以内；MAE = $\$17.14$ 与中位误差的 3.3 倍差距揭示——误差分布自身重尾，少数极端样本仍被低估（这也印证了式 (5) 裁剪的必要性）。

分类 $\text{AUC} = 0.866 \pm 0.005$ ，显著高于随机基线 0.5，但远未达到“完美可分”1.0——反映跨链套利存在固有随机性（对手盘行为、Guardian 签名抖动），本章特征集无法穷尽。阈值 $\tau = 0.5$ 下 $\text{Accuracy} = 82.3\%$ ，较 $\bar{y}^{\text{cls}} = 73.85\%$ 的朴素基线净提升 +8.5 pp。将阈值提高到 $\tau = 0.8$ ，Precision 跃至 93.5%，Recall 退至 66.2%——意味着只在模型置信度 > 0.8 时下单，下单中 ~94% 实际盈利，代价是漏掉 34% 的机会。这一 Precision-Recall 权衡直接支撑把模型作为策略侧的高置信度过滤器。Log-Loss = 0.386 也优于基线二项分布的 0.576。

Table 4: 模型性能（5 折 CV, $n = 15,497$ ）

指标	值
回归 R_{CV}^2	0.7987 ± 0.0269
回归 MAE	$\$17.14$
回归 Median AE	$\$5.13$
分类 AUC_{CV}	0.8658 ± 0.0052
分类 $\text{Accuracy} @ \tau = 0.5$	82.3% (基线 73.9%)
分类 $\text{Precision} @ \tau = 0.8$	93.5% (Recall 66.2%)
分类 Log-Loss	0.3864

5 局限性

Dust 过滤阈值的敏感性。我们以 $C_{\text{exec}}^{\text{in}} < \1 作为 dust 过滤阈值，此阈值的选择来自 Ethereum L1 swap 的最低 gas 物理下限（ $\$1-\5 ）。若阈值提高到 $\$5$ ，被过滤的样本从 12 条增至约 116 条（~ 0.4%），reliable 子集的 ROI 均值从 +7.83% 下降到约 +6.88%，中位数几乎不变（+1.39% $\rightarrow$ +1.38%）。两种阈值下第 4 节的 GBM 结果（ R^2 、AUC、Median AE）均未发生有统计意义的变化。我们采用较保守的 $\$1$ 阈值以最大化样本量并避免把“手续费高于本金但仍为真实亏损”的合法小额交易一起误删。

单桥样本偏差。本研究仅采集 Wormhole Portal 的候选，未涵盖 LayerZero V2、Mayan、Relay、CCIP 四条桥。第 1 节已论证 Wormhole 是这五条桥中 memecoin 覆盖最广、样本量最大的一条，且采用“消息层 + 代币包装”结构使套利候选可被精确重建。然而，Portal 的端到端延迟中位约 13 秒（Solana finality）叠加 ~13 分钟（Ethereum 两个 epoch）——这一数字是 Wormhole 特有的。在 LayerZero 或 intent-based 的 Mayan/Relay 上，延迟机制、尾部分布与套利窗口形态会显著不同；因此本章的模型参数与 R_{CV}^2 水平不应被直接外推到其他桥，跨桥对照是后续工作。

观察窗口与制度变迁。本数据覆盖约 365 天，期间 Solana 与 Ethereum 的费率环境、桥本身的 Guardian 签名节奏、以及头部机器人的行为均可能存在制度变迁（regime shift）。本章模型是混合期的平均结果，未做分段建模；若研究窗口拆为若干制度期，模型系数与 CV 表现均可能发生漂移。制度识别与分段建模留待后续工作。