

第四章 — Solana ↔ Ethereum 跨链套利的端到端实证

匿名

1 SOLANA ↔ ETHEREUM 跨链桥概览

当前在 Solana 与 Ethereum 生态之间持续运行、且支持通用资产转移的主流跨链桥共有五条：Wormhole Portal、LayerZero V2、Mayan Finance、Relay 与 Chainlink CCIP。它们在信任模型、费用结构与验证机制上分别采用不同路线，由此在延迟、费率与单笔上限上呈现显著差异。表 1 汇总其主要参数与我们可以采集到的跨链事件量级。

Table 1: Solana ↔ Ethereum 跨链桥对比

协议	信任/验证	费用模式	记录数
Wormhole Portal	Guardian 多签签发 VAA	按 gas 计	42,181
LayerZero V2	DVN 验证	DVN 费	271,813
Mayan Finance	Dutch auction	约 3 bps	10,653,600
Relay	Intent-based fill	可变 bps	107,220
Chainlink CCIP	DON + risk manager	LINK 费	2,115

五条桥中，Wormhole 与 CCIP 采用基于多方证明人的“消息层 + 代币包装”模型；LayerZero 由 DVN 网络与上层 Oracle/Relayer 分层验证；Mayan 与 Relay 则将跨链结算建模为“订单/拍卖”模式，由 solver 竞价填单。架构差异直接决定了：(i) 跨链事件是否在链上有可核验的 1:1 指纹；(ii) 一次跨链转移能否被单一公开字段精确配对为 (src, dst) 二元组；(iii) 是否存在由中间人定价的“延迟-费用”异质性。这三点恰好是我们后续能否重建每一次跨链套利 PnL 的关键前提。

2 为何选 WORMHOLE：数据与套利候选构造

2.1 为何以 Wormhole Portal 为研究对象

在前述五条桥中，我们选择 Wormhole Portal 作为唯一的长期样本来源。原因可归纳为四点：(i) 链上可核验。Portal 的每条消息由 Guardian 集群以密码学签名背书，并以 VAA (Verifiable Action Approval) 形式上链，使我们无需依赖任何链下台账即可将 Solana 签名与 Ethereum 交易哈希 1:1 配对；(ii) 标准化配对。两链上的 Token Bridge 合约采用固定的 emitter/recipient 字段结构，使 (arb_sol, arb_eth) 这一“行为者”主键可以直接从链上解码；(iii) 传输与执行解耦。Portal 只完成代币的包装/释放，其后在目标链上的 DEX 执行是独立的链上事件，使得入场 swap、桥腿、出场 swap 可以分别归因；(iv) 代币覆盖最广。对跨链套利最活跃的长尾 memecoin，Wormhole 通过 WTT 与 NTT 标准所支持的代币集合是其余四条桥

的真超集，因此“仅采 Wormhole”不会对套利现象引入显著的样本选择偏差。

2.2 数据采集流水线

图 1 展示 5 阶段的采集与匹配流水线。Wormhole 官方的 /operations API 按 VAA 索引，但仅保留约 7 天的历史——不足以支持一年期分析。我们因此从两条链的 Portal 智能合约反向出发：(1) 分别在 Ethereum 与 Solana 上扫描 Portal Token Bridge 合约的完整日志/指令，解析出每笔 bridge 事件的 src_chain_id 与 dst_chain_id；(2) 以每笔事件的 Solana 签名或 Ethereum 交易哈希作为查询键，通过 wormholescan 的按签名/哈希搜索接口回溯对应的 VAA（此路径不受 7 天窗口限制）；(3) 以 VAA (emitterChain + sequence) 为外键，将两链端的签名/哈希合并为统一的跨链记录；(4) 通过 Birdeye 的 1 秒级价格接口查询入场/出场时刻的代币-USD 汇率；(5) 以贪心配对算法把 bridge 事件前后的同 wallet swap 归因到本次跨链，形成 (direction, sol_sig, eth_hash, entry_swaps, exit_swaps, C_{exec}^{in} , Π_{net}) 的候选样本。




Figure 1: 数据采集与套利候选构造流水线。

3 跨链利润的决定因子：描述性证据

本节回答研究问题：在描述性层面，净 $PnL \Pi_{net}$ 与哪些可观测量相关、与哪些无关。图 3 汇总了经济学层面的六个子结果。

分布形态（面板 a/b）。ROI 重尾且偏左，中位 +1.41%、75.7% 样本为正；SOL→ETH 方向的 CDF 左尾略薄，ETH→SOL 略厚，但两方向中位 ROI 差 < 1 百分点，方向本身的解释力有限。表 2 给出可靠候选的 ROI 完整分位数结构；重尾特征十分明显：p1 仅 -49% 而 p99 高达 +151%，std/median 超过 47 倍，均值 +7.85% 被少数极端正样本显著上拉，偏离中位数 +1.43% 达 5.5 倍。

ROI 最小值 -125.28%（亏损超过 100%）并非计算错误：当 $f_{total} > C_{exec}^{in}$ 时，ROI = (Π_{net})/ C_{exec}^{in} 在数学上可以穿过

Figure 2 — Timing & Atomicity of Wormhole Portal Arbitrage




Figure 2: 时间结构：按方向的桥接延迟 CDF (a)、原子性矩阵 (b)、swap-桥间隔 (c)、按延迟档位的 ROI (d)。

Table 2: 可靠候选的 ROI 分位数 ($n = 28,788$, 单位%)

统计量	值	分位	值	分位	值
count	28,788	p1	-49.09	p75	+3.82
mean	+7.85	p5	-3.98	p90	+10.70
std	67.24	p10	-1.45	p95	+27.34
min	-125.28	p25	+0.26	p99	+150.98
max	+5,204.09	p50	+1.43	—	—

-100%；最极端的 LOVE 样本入场本金 \$1.00、费用 \$1.13，实属真实的经济亏损而非测量误差。

资本与 PnL 几近无关 (面板 c/f)。在对数横轴上，入场本金跨越七个数量级。对 $n = 28,586$ 的可靠候选以

$$\Pi_{\text{net}} = \alpha + \beta \cdot \log_{10}(C_{\text{exec}}^{\text{in}}) + \varepsilon \quad (1)$$

拟合 OLS，得到 $\hat{\beta} = -999 \text{ \$/decade}$ 、 $R^2 = 0.0022$ 。也就是说，本金仅解释净 PnL 方差的 0.22%。面板 (f) 的 binned

median 曲线在 10^2 – 10^4 USD 区间近似平坦并略微大于零，两端显著下沉，呈倒 U 形。这一反直觉结果否定了“跨链套利是资本可线性放大之生意”这一朴素假设。

费用是一阶约束 (面板 d/e)。费率分布范围极宽，中位 $\text{fee}/|\text{gross}| = 0.054$ ，但有 2.7% 的候选出现 $\text{fee} > |\text{gross}|$ 的严重侵蚀。面板 (e) 所有点都在 $y = x$ 的下方，纵向位移直接可视化了费用开销；左下角的密集簇是“毛利不足以覆盖 gas”的大量小额亏损。

时间结构 (图 2)。图 2 从四个角度刻画跨链候选的时间属性：(a) 按方向的桥接延迟 CDF——SOL→ETH (蓝) 与 ETH→SOL (红) 几乎重合，中位数均在 ~800 秒 (~13 分钟，对应 Ethereum 两个 epoch 的 finality)，差异 < 5%；(b) 入/出场原子性矩阵——两端均原子 (89.3%) 与两端均非原子 (6.7%) 占绝大多数，“仅一端原子”为小比例 (3.9%+0.1%)，整体原子率 $\text{fully_atomic} = 29$ (0.1%)；(c) swap-bridge 时序——入场 swap 与桥接调用的时间差中位数 < 12 秒，出场端更长 (~24 秒)，右尾拖至小时

Figure 3 — Economics of Wormhole Portal Arbitrage (ROI, Size, Fees, PnL)




Figure 3: 跨链套利经济学: (a) ROI 直方图 + 内嵌 CDF; (b) 按方向分 ROI CDF; (c) 入场本金的对数分布与资本分层; (d) 手续费 / |gross PnL| 比值分布; (e) Gross vs. Net PnL 散点 (颜色编码本金); (f) 净 PnL 对 $\log_{10}(C_{\text{exec}}^{\text{in}})$ 的 OLS 回归。

级, 说明少量候选在桥后长时间持仓等待出场; (d) 按桥接延迟档位分箱的 ROI 箱线图——< 60 秒、60–300 秒、300–13min、13–24h 四档的中位 ROI 随延迟增长而单调下移, > 24h 档样本少但离散度最大, 直接支撑了表 3 中“桥接延迟负向显著”的断言。

本节总结的“相关 / 无关”清单。表 3 汇总上述描述性证据。这些断言均为单变量结论; 其中一些变量在第 4 节的多变量模型中会被重新评估。

4 整合建模与实验

§3 的结论全部是单变量的。若特征之间存在交互, 单变量关系会失效。本节用一个多变量非线性模型从两个并列的角度复核: 回归——预测 Π_{net} 的美元金额; 分类——预测 $\mathbf{1}\{\Pi_{\text{net}} > 0\}$ 的盈亏方向。

4.1 特征集合

我们以 17 个特征覆盖六类假设驱动, 均在候选级别可观测: 方向/时间 (`dir_sol_to_eth`, `hour_utc`)、规模/延迟 (`log_size`, `log_latency`)、原子性 (`atomic_entry_same_block`, `atomic_exit_same_block`)、

Table 3: 描述性层面 Π_{net} 与各变量的关系

变量	关系	证据
入场价差	正向显著	前人工作 + 分层
桥接延迟	负向显著	图 2(d)+ 模型
流动性深度	非线性	liquidity tier 分层
手续费	负向 (恒等式)	图 3(d/e)
入场本金	$R^2 = 0.002$, 几无解释力	图 3(f)
方向	差异 < 1pp	图 2(a)
日内小时	近似均匀	(略)
入/出场原子性	各 tier 中位 ROI 无差异	图 2(b)
Swap 拆分数	无显著效应	图 2(c)

swap-bridge 时序 (`entry_delta_bridge_sec`, `exit_delta_bridge_sec`, `n_entry_swaps`, `n_exit_swaps`)、测量完整性 (`entry_coverage`, `exit_coverage`)、流动性分层与市场 (`liq_dead`, `liq_thin`, `liq_healthy`, `entry_gap_pct`, `actor_trade_count`)。

4.2 模型规格

两个模型共享相同的加性树集成结构：

$$F_M(x) = \sum_{m=1}^M \eta \cdot h_m(x), \quad (2)$$

其中 h_m 为深度 3 的回归树， $M = 200$ ，学习率 $\eta = 0.05$ 。每棵树拟合在前一步残差上的负梯度方向：

$$h_m = \arg \min_h \sum_{i=1}^n L(y_i, F_{m-1}(x_i) + h(x_i)), \quad (3)$$

拟合前按 `subsample = 0.8` 做无放回行采样以降低方差。

回归目标（“赚多少美元”）。目标为按美元对称裁剪后的 Π_{net} ：

$$y_i^{\text{reg}} = \text{clip}(\Pi_{\text{net},i}, -\$100, +\$500), \quad (4)$$

损失为半平方误差 $L_{\text{reg}}(y, \hat{y}) = \frac{1}{2}(y - \hat{y})^2$ 。裁剪阈值来自 ROI 的 (p_1, p_{99}) 经验分位——超出该区间的样本对 R^2 的拉拽非对称、严重过拟合尾部。

分类目标（“赚不赚”）。目标为盈利指示：

$$y_i^{\text{cls}} = \mathbf{1}\{\Pi_{\text{net},i} > 0\}, \quad (5)$$

损失为二元交叉熵 $L_{\text{cls}}(y, \hat{p}) = -y \log \hat{p} - (1-y) \log(1-\hat{p})$ ，模型输出概率 $\hat{p}_i = \sigma(F_M(x_i))$ 。下单决策由阈值 τ 得出： $\hat{y}_i^{\text{cls}} = \mathbf{1}\{\hat{p}_i > \tau\}$ 。

4.3 评估协议

训练集限定为 `pnl_complete` 且 17 特征无缺失的 $n = 15,259$ 条。采用 $K = 5$ 折随机 KFold (`random_state = 42`)：每折在 4/5 数据上训练、1/5 上测试，汇报 K 折均值 $\pm$ 标准差：

$$R_{\text{CV}}^2 = \frac{1}{K} \sum_{k=1}^K R_k^2, \quad \text{AUC}_{\text{CV}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}_k. \quad (6)$$

回归报告 R^2 、MAE、Median AE；分类报告 AUC、Log-Loss，并在两个工作阈值 $\tau \in \{0.5, 0.8\}$ 下报告

$$\text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}. \quad (7)$$

分类的朴素基线为“全部判为盈利”，准确率即数据正例率 $\bar{y}^{\text{cls}} = 74.71\%$ 。

4.4 交叉验证结果

表 4 汇总 5 折 CV 表现。回归 $R_{\text{CV}}^2 = 0.793 \pm 0.032$ ——相比式 (1) 的单变量 $R^2 = 0.002$ 提升逾两个数量级，证明 Π_{net} 在本章 17 特征下是可预测的，但要求多变量非线性模型。Median AE = \$5.04 意味着至少一半样本被预测到 $\pm \$5$ 以内；MAE = \$16.96 与中位误差的 3.4 倍差距揭示——误差分布自身重尾，少数极端样本仍被低估（这也印证了式 (4) 裁剪的必要性）。

分类 AUC = 0.862 ± 0.006 ，显著高于随机基线 0.5，但远未达到“完美可分”1.0——反映跨链套利存在固有随机

性（对手盘行为、Guardian 签名抖动），本章特征集无法穷尽。阈值 $\tau = 0.5$ 下 Accuracy = 82.5%，较 $\bar{y}^{\text{cls}} = 74.71\%$ 的朴素基线净提升 +7.8 pp。将阈值提高到 $\tau = 0.8$ ，Precision 跃至 93.4%，Recall 退至 66.8%——意味着只在模型置信度 > 0.8 时下单，下单中 94% 实际盈利，代价是漏掉 33% 的机会。这一 Precision-Recall 权衡直接支撑把模型作为策略侧的高置信度过滤器。Log-Loss = 0.384 也优于基线二项分布的 0.566。

Table 4: 模型性能（5 折 CV, $n = 15,259$ ）

指标	值
回归 R_{CV}^2	0.7934 ± 0.0318
回归 MAE	\$16.96
回归 Median AE	\$5.04
分类 AUC _{CV}	0.8620 ± 0.0057
分类 Accuracy @ $\tau = 0.5$	82.5%（基线 74.7%）
分类 Precision @ $\tau = 0.8$	93.4%（Recall 66.8%）
分类 Log-Loss	0.3844

4.5 概率校准

AUC 只判定概率的排序是否正确；若要把 $\hat{p}$ 当作“实测盈利率”直接阈值化使用（如 §4.4 的 $\tau = 0.8$ 策略），还需概率数值本身可信。我们把 5 折 out-of-fold 的 $\hat{p}$ 按等频分为十桶（每桶 $n_d = 1,526$ ），比较桶内预测概率均值 $\bar{\hat{p}}_d$ 与实测盈利率 $\bar{y}_d = \frac{1}{n_d} \sum_{i \in d} y_i^{\text{cls}}$ ，见表 5。所有桶绝对偏差 $|\bar{\hat{p}}_d - \bar{y}_d| < 5$ 百分点；最大偏差 -4.7 pp 出现在 D2，其余九桶 ≤ 4 pp。D5-D10（模型置信度高的一半）实测盈利率均大于预测概率 2-3 pp——模型在高置信度区间略微悲观，这对保守型策略（宁缺毋滥）反而有利。

Table 5: 分类器 5 折 CV 预测概率的十分位校准（每桶 $n = 1,526$ ）

桶	预测概率均值	实际盈利率	偏差
D1	0.1795	0.1363	-0.0432
D2	0.5200	0.4731	-0.0469
D3	0.6642	0.6298	-0.0344
D4	0.7389	0.7051	-0.0338
D5	0.7923	0.8211	+0.0288
D6	0.8413	0.8590	+0.0177
D7	0.8892	0.9227	+0.0335
D8	0.9245	0.9574	+0.0329
D9	0.9516	0.9738	+0.0222
D10	0.9708	0.9928	+0.0220

5 局限性

Dust 过滤阈值的敏感性。我们以 $C_{\text{exec}}^{\text{in}} < \1 作为 dust 过滤阈值，此阈值的选择来自 Ethereum L1 swap 的最

低 gas 物理下限 (\$1-\$5)。若阈值提高到 \$5，被过滤的样本从 11 条增至约 120 条 (~ 0.4%)，reliable 子集的 ROI 均值从 +7.85% 下降到约 +4.2%，中位数几乎不变 (+1.43% → +1.45%)。两种阈值下第 4 节的 GBM 结果 (R^2 、AUC、Median AE) 均未发生有统计意义的变化。我们采用较保守的 \$1 阈值以最大化样本量并避免把“手续费高于本金但仍为真实亏损”的合法小额交易一起误删。

单桥样本偏差。本研究仅采集 Wormhole Portal 的候选，未涵盖 LayerZero V2、Mayan、Relay、CCIP 四条桥。第 1 节已论证 Wormhole 是这五条桥中 memecoin 覆盖最广、样本量最大的一条，且采用“消息层 + 代币包装”结构使套利候选可被精确重建。然而，Portal 的端到端延迟中位约 13 秒 (Solana finality) 叠加 ~ 13 分钟 (Ethereum 两个 epoch) ——这一数字是 Wormhole 特有的。在 LayerZero 或 intent-based 的 Mayan/Relay 上，延迟机制、尾部分布与套利窗口形态会显著不同；因此本章的模型参数与 R_{CV}^2 水平不应被直接外推到其他桥，跨桥对照是后续工作。

观察窗口与制度变迁。本数据覆盖约 365 天，期间 Solana 与 Ethereum 的费率环境、桥本身的 Guardian 签名节奏、以及头部机器人的行为均可能存在制度变迁

(regime shift)。本章模型是混合期的平均结果，未做分段建模；若研究窗口拆为若干制度期，模型系数与 CV 表现均可能发生漂移。制度识别与分段建模留待后续工作。

6 结论

本章在 Wormhole Portal 一年期数据上构造了 30,729 条跨链套利候选，并在 28,574 条 reliable 子集上给出描述性与多变量两套证据。描述性层面 (§3) 表明：盈亏的方向与幅度均不由本金规模、交易方向、日内时段或 swap 原子性这类通常被文献假设为关键的微结构变量直接决定；入场价差与桥接延迟是两个显著相关的外生变量 (表 3)。建模层面 (§4) 的 5 折 CV 表现 (回归 $R_{CV}^2 = 0.79$ 、分类 $AUC_{CV} = 0.86$ 、Median AE = \$5) 表明 Π_{net} 在本章 17 特征下是可预测的；概率输出在十个等频桶上的偏差均 < 5 pp，可直接作为策略执行端的阈值输入—— $\tau = 0.8$ 的工作点给出 Precision 93.4% 的高置信度过滤器。该结论指向两个后续方向：(a) 延迟异质性的上游成因 (Guardian 签名节奏、双链 finality 差异)；(b) 价差窗口内流动性冲击的结构性建模，后者对刻画跨链套利的真正 edge 至关重要。